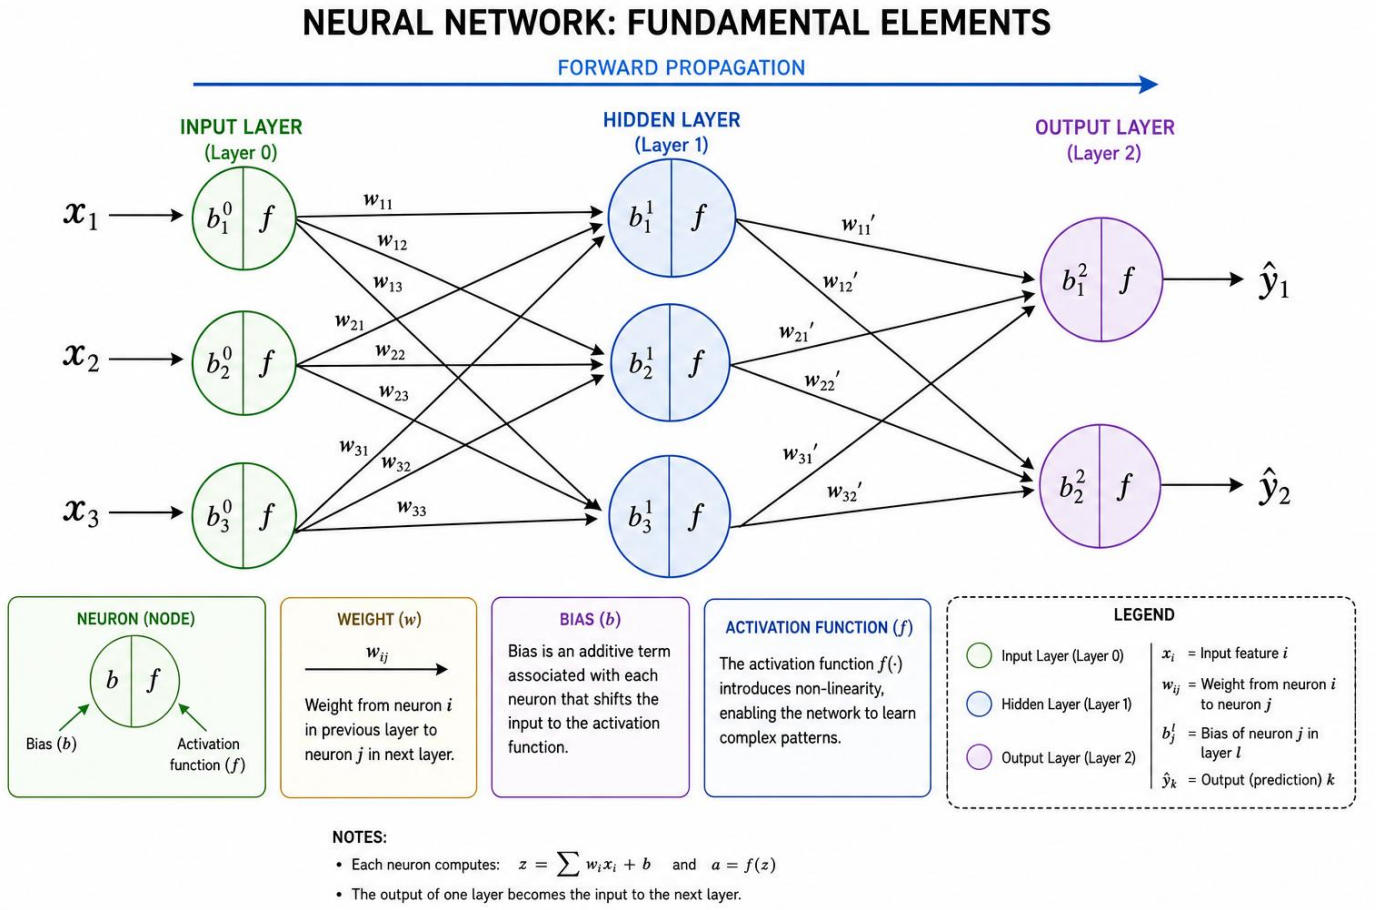
Elementos Fundamentais de uma Rede Neural

Uma rede neural artificial é composta neurônios artificiais que são as unidades básicas de processamento, eles são organizados em camadas e conectados por pesos.

Abaixo está a ilustração de um diagrama básico completo[1]. Este diagrama será detalhado em seguida.



1. Neurônios (Nós)

São as unidades fundamentais de processamento, esta arquitetura foi inspirada no neurônio biológico humano e funciona em 3 etapas:

- **Entrada (dendritos):** recebe os sinais das camadas anteriores
- **Processamento (soma):** combina os sinais de forma ponderada
- **Saída (axônio):** transmite o resultado para os próximos neurônios

[1] Imagem gerada por IA

2. Camadas (Layers)

Os neurônios são organizados em camadas, que formam a arquitetura da rede, em uma rede padrão, cada neurônio de uma camada se conecta com todos os neurônios da camada seguinte. A tabela abaixo explica as camadas da rede neural.

Camada	Função
Camada de Entrada	Recebe os dados brutos — cada neurônio representa uma feature (característica) do dado de entrada.
Camadas Ocultas	Realizam o processamento intermediário — é onde a rede extrai padrões, combina características e aprende representações abstratas. Pode haver várias camadas ocultas (deep learning) e em cada camada pode haver qualquer quantidade de neurônios, independente da quantidade de features de entrada ou classes de saída
Camada de Saída	Produz o **resultado final**: uma classificação, um valor numérico, uma probabilidade, etc., é gerado um neurônio para cada classe de saída

3. Pesos (Weights) — w_i

Cada conexão entre neurônios possui um peso, que determina a força da influência de uma entrada sobre o neurônio seguinte.

- Valores altos → maior impacto na ativação
- Valores negativos → relação inibitória

Estes pesos são ajustados durante o treinamento através de um processo chamado backpropagation. Eles são a "memória" da rede — é neles que o aprendizado é armazenado.

4. Bias (Viés) — b

O bias é um parâmetro adicional que funciona como um intercepto (semelhante ao b da equação da reta y = ax + b).

Permite que o neurônio seja ativado mesmo quando todas as entradas são zero, ele dá flexibilidade à rede para aprender padrões que não passam pela origem. Cada neurônio (exceto os da camada de entrada) possui seu próprio bias

5. Soma Ponderada (Net Input) — z

Antes da ativação, o neurônio calcula uma combinação linear de todas as entradas:

$$Z = \sum_{i=1}^{n} wi\ xi + b$$

Onde:

w_i = peso da conexão i
x_i = valor de entrada i
b = bias

6. Função de Ativação — f(z)

É a função matemática que decide se o neurônio "dispara" ou não, introduzindo não-linearidade na rede (essencial para aprender padrões complexos). A tabela a seguir mostra as principais funções de ativação.

Função	Fórmula	Uso típico
ReLU	$f(z) = max(0, z)$	Mais comum em camadas ocultas
Sigmoid	$f(z) = \frac{1}{1+e^{-z}}$	Saídas binárias (0 ou 1)
Tanh	$f(z) = \frac{e^{z} - e^{-z}}{e^{z} + e^{-z}}$	Valores normalizados entre -1 e 1
Softmax	$f(z_i) = \frac{e^{z_i}}{\sum_j e^{z_j}}$	Classificação multiclasse

A saída final do neurônio é:

$$a = f(z) = f\left(\sum w_i x_i + b\right)$$

7. Forward Propagation

É o fluxo de propagação para frente: os dados entram pela camada de entrada, percorrem cada camada oculta (calculando soma ponderada + ativação em cada neurônio) e chegam à camada de saída, que produz a predição $\hat{y}$.

8. Backpropagation

É o algoritmo de treinamento que calcula o erro entre a saída predita $\hat{y}$ e o valor real y, propaga esse erro para trás, camada por camada, ajusta pesos e biases usando Gradiente Descendente para minimizar o erro.

A rede neural repete o ciclo (forward → erro → backward → ajuste) por várias iterações até a rede aprender.

Resumindo a rede neural recebe x (as features de entrada), multiplica por pesos w, soma o bias b, aplica a ativação f(z) e produz uma saída. O aprendizado ajusta w e b para que $\hat{y}$ se aproxime do y (valor real).